

Projet 9 : Prédire la consommation électrique

Sommaire

Introduction

L'effet température

Stationnarité

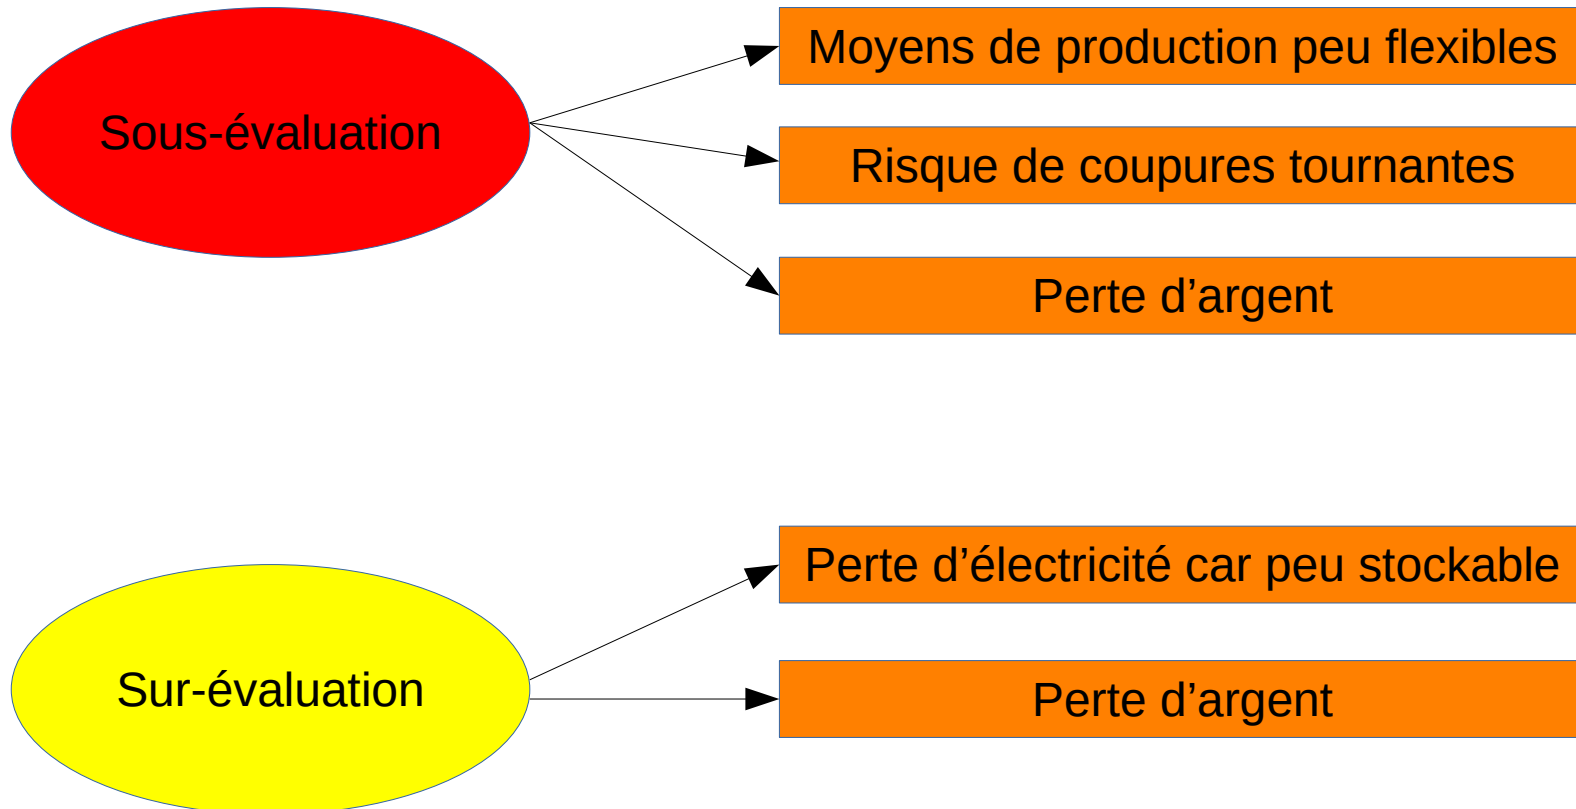
Les modèles de prédiction

Conclusion

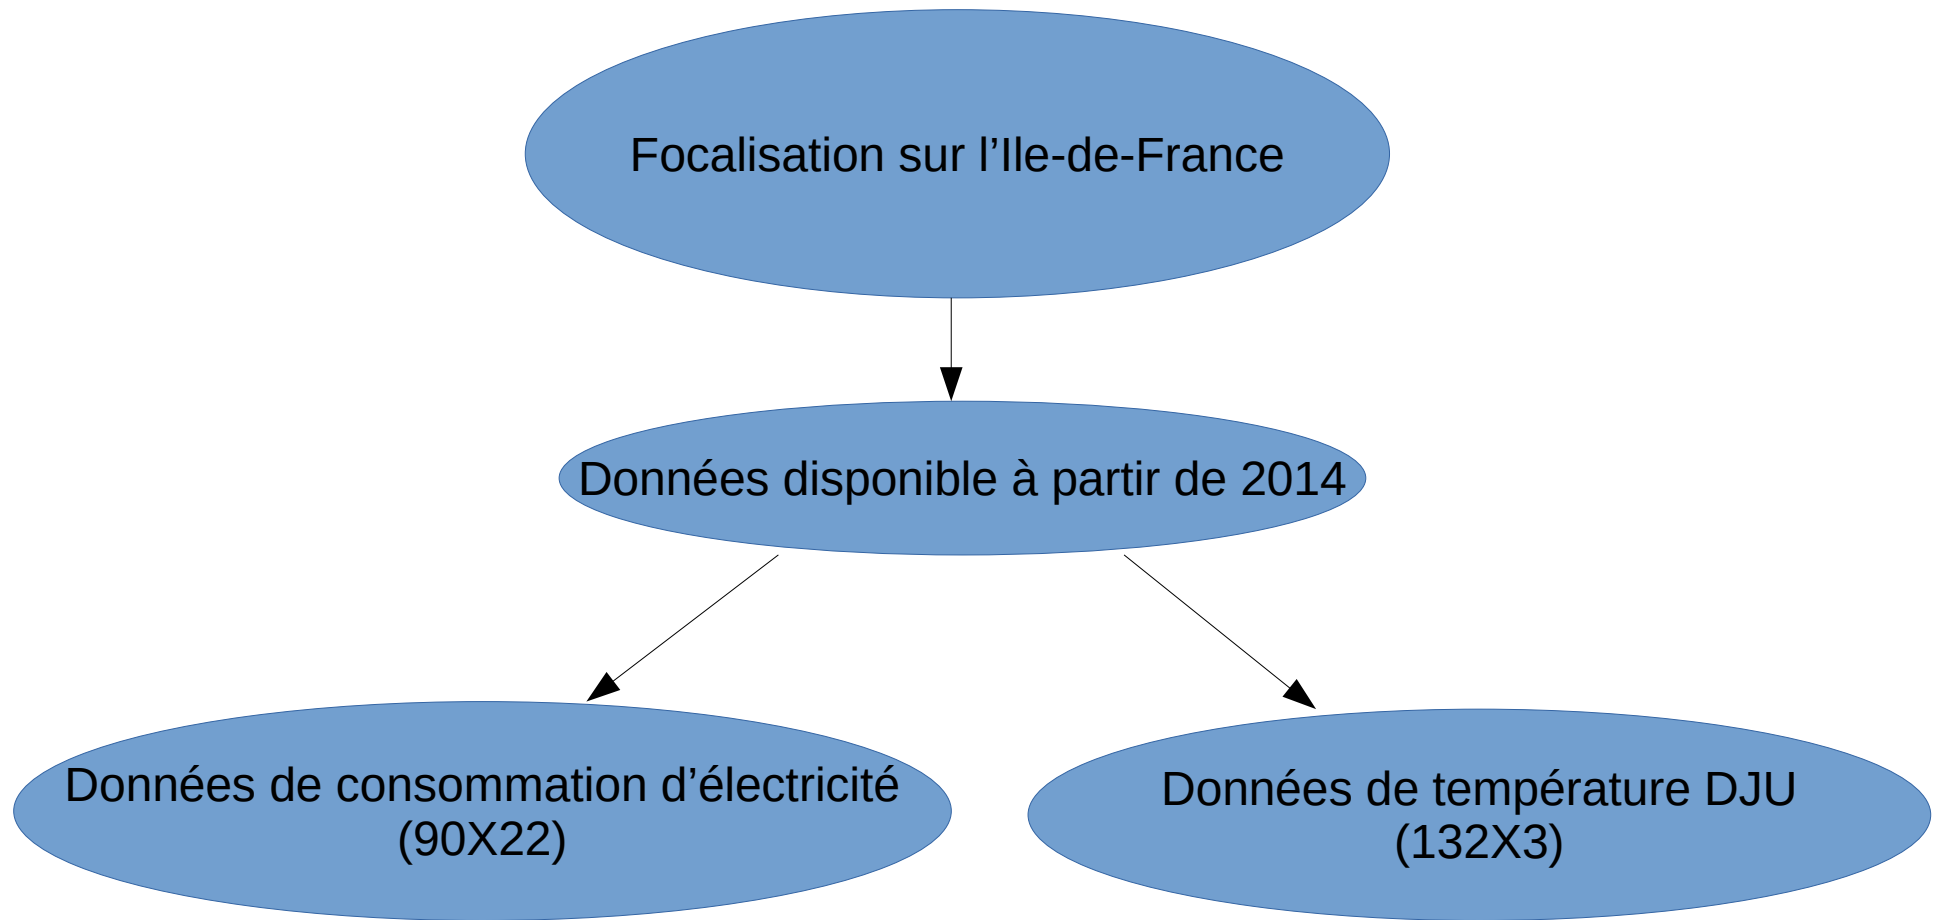
Introduction

Introduction

La prévision est une nécessité pour l'équilibre entre l'offre et la demande électrique




Les données



L'effet température

Analyse des variables



En superposant les variables, on constate qu'elles ont des variations corrélées
Par ailleurs, on constate que plus les températures sont basses et plus la consommation est forte

Analyse de l'effet température

OLS Regression Results						
=====						
Dep. Variable:	Consommation totale		R-squared:	0.964		
Model:	OLS		Adj. R-squared:	0.964		
Method:	Least Squares		F-statistic:	1888.		
Date:	Fri, 04 Dec 2020		Prob (F-statistic):	2.23e-52		
Time:	16:12:12		Log-Likelihood:	-492.48		
No. Observations:	72		AIC:	989.0		
Df Residuals:	70		BIC:	993.5		
Df Model:	1					
Covariance Type:	nonrobust					
=====						
	coef	std err	t	P> t	[0.025	0.975]


const	4510.3590	42.417	106.334	0.000	4425.761	4594.957
DJU	8.4947	0.195	43.454	0.000	8.105	8.885
=====						
Omnibus:	0.180		Durbin-Watson:	2.185		
Prob(Omnibus):	0.914		Jarque-Bera (JB):	0.340		
Skew:	-0.094		Prob(JB):	0.844		
Kurtosis:	2.720		Cond. No.	341.		
=====						

Via la régression linéaire on confirme la forte corrélation des variables :
DJU explique 96 % de la variance

Suppression de l'effet température

Pour supprimer l'effet température on soustrait à la consommation la variable DJU multiplié par son coefficient de régression

Représentation graphique du modèle original vs le modèle corrigé de la température :




Sans l'effet de température, la consommation d'électricité est bien plus stable dans le temps

Stationnarité

Correction par les moyennes mobiles

Nous tentons de corriger la saisonnalité via soustraction de la moyenne mobile sur 12 mois



En réalité on stabilise la moyenne à 0, ceci afin de tenter de supprimer l'effet de tendance

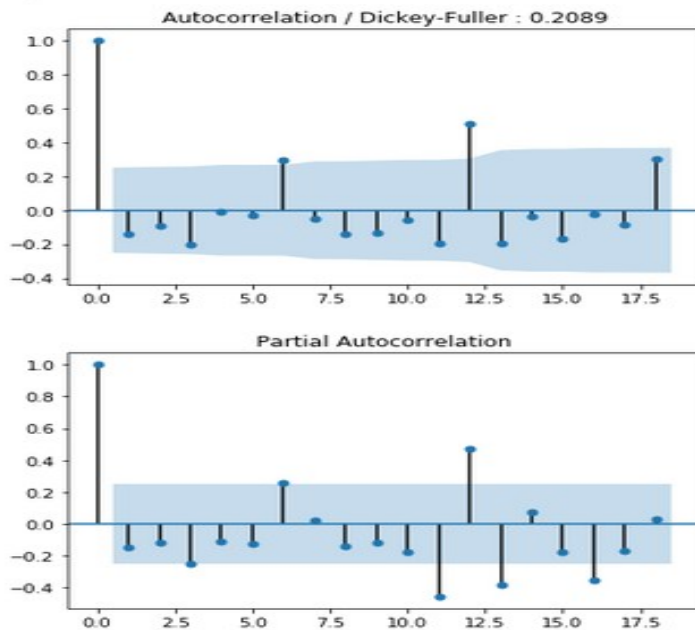
Notion de stationnarité

Soustraction de la moyenne mobile : méthode pour tenter de stationnariser une série temporelle

Série stationnaire

Tendance nulle

Saisonnalité nulle


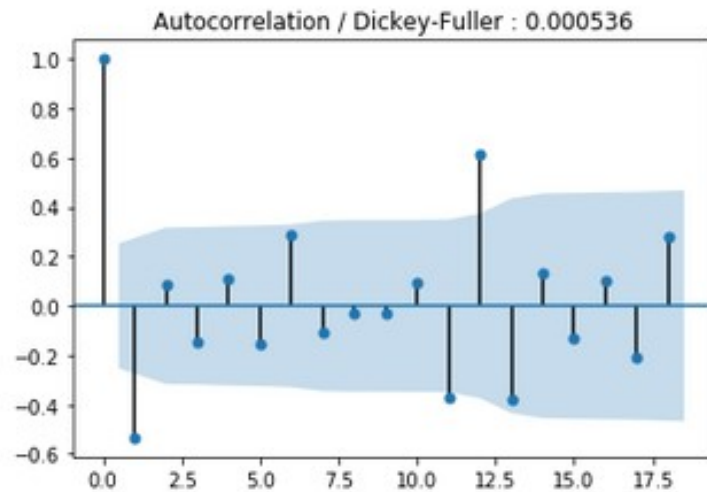


Test Dickey-Fuller : $pvalue > 0.05$

Saisonnalité présente en multiple de 6

Par conséquent, l'hypothèse de stationnarité n'est pas vérifiée

Solution stationnaire



On applique une différenciation à la série pour tenter de la stationnariser

Test Dickey-Fuller : $pvalue < 0.05$

Pas de décroissance vers 0 sur l'auto corrélation, qui aurait indiqué la présence d'une tendance


Par conséquent, l'hypothèse de stationnarité est vérifiée

Modèle de prédiction

Holt-Winters

Double lissage exponentiel

Plus les valeurs sont anciennes moins leur poids est important



The Mean Squared Error is 22577.75
The Root Mean Squared Error is 150.26
The Mean Absolute Percentage Error is 3.21%

MAPE = 3,21 % (bonne efficacité)

SARIMA

S : Saisonnalité – AR : Autocorrélation – I : Intégré – MA : Moyenne mobile

```
3]: p = range(0, 3)
d = range(0, 2)
q = range(0, 2)
pdq = list(itertools.product(p, d, q))
seasonal_pdq = [(x[0], x[1], x[2], 12) for x in list(itertools.product(p, d, q))]
best_aic = 0
for param in pdq:
    for param_seasonal in seasonal_pdq:
        try:
            mod = sm.tsa.statespace.SARIMAX(y, order=param, seasonal_order=param_seasonal, enforce_stationarity=False, enforce_invertibility=False)
            results = mod.fit()
            if ((best_aic == 0) | (best_aic > results.aic)) & (results.pvalues.max() <= 0.05) \
            & (sm.stats.diagnostic.acorr_ljungbox(results.resid, lags=[12], return_df=False)[1] > 0.05):
                best_aic = results.aic
                best_pvalue = results.pvalues.max()
                best_param = param
                best_param_seasonal = param_seasonal
        except:
            continue
print('Meilleurs paramètres : SARIMAX({}x{}) - AIC:{}'.format(best_param, best_param_seasonal, best_aic))

mod = sm.tsa.statespace.SARIMAX(y,
                                order=(best_param),
                                seasonal_order=(best_param_seasonal),
                                enforce_stationarity=False,
                                enforce_invertibility=False)

results = mod.fit()
print(results.summary())
```

Meilleurs paramètres : SARIMAX(0, 0, 1)x(2, 1, 0, 12) - AIC:313.62856999320286

SARIMAX Results

Dep. Variable:	Mois, Consommation	No. Observations:	60
Model:	SARIMAX(0, 0, 1)x(2, 1, [], 12)	Log Likelihood	-152.814
Date:	Thu, 17 Dec 2020	AIC	313.629
Time:	18:35:53	BIC	318.341
Sample:	01-01-2015 - 12-01-2019	HQIC	314.879

Covariance Type: opg

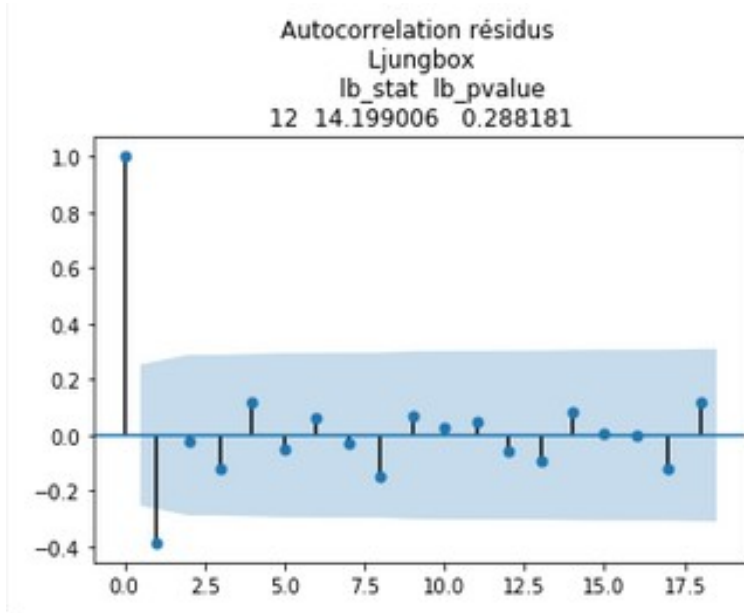
	coef	std err	z	P> z	[0.025	0.975]
ma.L1	-0.5163	0.231	-2.234	0.025	-0.969	-0.063
ar.S.L12	-0.7797	0.184	-4.230	0.000	-1.141	-0.418
ar.S.L24	-0.4620	0.206	-2.245	0.025	-0.865	-0.059
sigma2	1.97e+04	5269.011	3.739	0.000	9374.450	3e+04

Ljung-Box (L1) (Q): 0.35 Jarque-Bera (JB): 3.17
Prob(Q): 0.55 Prob(JB): 0.21
Heteroskedasticity (H): 0.38 Skew: 0.84
Prob(H) (two-sided): 0.19 Kurtosis: 3.60

Méthode choix du modèle
SARIMA :

Minimisation AIC
Critère de vraisemblance < 0.05
Blancheur des résidus > 0.05


SARIMA : Analyse des résidus



Test blancheur des résidus : 0,29

Démontre que les résidus sont indépendants

This distribution has skew -0.439543418480271
This distribution has kurtosis 0.8484512859588667
Test Shapiro-Wilk : hypothèse de normalité ne peut pas être rejetée
pvalue = 0.13924600300710077




Test de normalité des résidus :

Shapiro-Wilk = 0,14 (hypothèse de normalité vérifié)

SARIMA : Analyse des résidus


S : Saisonnalité – AR : Autocorrélation – I : Intégré – MA : Moyenne mobile



The Mean Squared Error is 12261.81
The Root Mean Squared Error is 110.73
The Mean Absolute Percentage Error is 2.03%

MAPE = 2,03% (bonne efficacité)

Comparaison Holt-Winters et SARIMA



Holt-Winters prédit une tendance à la hausse
SARIMA à la baisse plus corrélée à la tendance de la série

SARIMA améliore de 1,18 % le MAPE

Conclusion

Dans le domaine de l'électricité la prédiction est d'une importance capitale, afin d'adapter au mieux les moyens de production et d'éviter des coupures.

Comme on a pu le constater la température est fortement corrélée à la consommation électrique, seulement pour prédire la consommation il faut la soustraire aux données en déterminant son coefficient de régression.

Mais l'étape la plus importante est de stationnariser notre série temporelle afin d'avoir le modèle de prédiction le plus efficace possible et éviter l'influence d'une tendance ou d'une saisonnalité, plusieurs méthodes existent dans notre cas la méthode de différenciation a été la plus efficace.

On a pu utiliser ensuite deux méthodes pour prédire notre future consommation : Holt-Winters et son double lissage exponentiel et SARIMA.

Au final le modèle SARIMA est le plus performant avec un pourcentage moyen d'erreur absolu à 1,82 %, une amélioration de 1,18 % par rapport à la méthode Holt-Winters.